Detecção de pneumonia em imagens de raio-X com modelo híbrido de CNN e classificadores

Vitor Augusto Lemes Pinheiro dos Santos[1]*; Ricardo Janes[2]

[1]Bacharel em Ciência da Computação. R. Ibitirama, 134 – Vila Prudente; 03134-000 São Paulo, SP, Brasil
[2] Doutor em Engenharia Elétrica. Av. Humberto de Alencar Castelo Branco, 3972-B – Assunção; 09850-901 São Bernardo do Campo, SP, Brasil
*autor correspondente: vitor.alp20@outlook.com

Modelo híbrido baseado em CNN e Classificadores para detecção de pneumonia em imagens de raio-x

Resumo

A detecção de pneumonia em imagens de raio X de tórax foi relevante para apoiar o diagnóstico clínico e reduzir riscos associados ao atraso na identificação da doença. Este estudo teve como objetivo desenvolver e avaliar um modelo híbrido para a detecção de pneumonia em radiografias torácicas. Para isso, a metodologia utilizou o conjunto de dados BRAX, após etapas de seleção, balanceamento, particionamento em treino, validação e teste, além da aplicação de técnicas de aumento de dados. As arquiteturas VGG16 e ResNet50 pré-treinadas no “ImageNet” atuaram como extratoras de características com ajuste fino parcial e foram combinadas aos classificadores “Random Forest”, XGBoost e “Support Vector Machine”. O estudo também realizou busca de hiperparâmetros com “GridSearchCV” para otimizar o desempenho dos modelos híbridos. Os resultados indicaram desempenho consistente entre as combinações avaliadas, com destaque para o modelo híbrido VGG16 + XGBoost.
Palavras-chave: detecção de pneumonia; aprendizagem por transferência; extração de características; classificadores; inteligência artificial.

Introdução

A pneumonia foi caracterizada como uma infecção pulmonar aguda associada à inflamação dos alvéolos. A doença foi classificada conforme o local de aquisição, podendo ser pneumonia adquirida na comunidade [PAC] ou pneumonia hospitalar, conforme o estado imunológico do paciente e o agente etiológico, geralmente bactérias, vírus ou fungos (Lim, 2020).

De acordo com a Organização Mundial da Saúde (OMS, 2025), a pneumonia esteve entre as principais causas de mortalidade no mundo, sendo responsável por cerca de 14% das mortes de crianças menores de cinco anos. No Brasil, a doença apresentou elevado número de internações anuais e taxas expressivas de mortalidade (Saúde, 2025). Nesse contexto, o diagnóstico precoce foi essencial para aumentar a eficácia do tratamento e reduzir os óbitos.

Entretanto, a análise de radiografias torácicas realizada por radiologistas depende fortemente da experiência profissional, o que aumentou a possibilidade de erros de interpretação e atrasos decorrentes da alta demanda e da escassez de especialistas (Ayan et al., 2021).

A interpretação de imagens radiográficas foi uma tarefa desafiadora devido à sobreposição de estruturas anatômicas e à semelhança entre diferentes patologias pulmonares. Nesse cenário, o uso de técnicas de Inteligência Artificial [IA] ganhou destaque como ferramenta de apoio à decisão clínica, pois viabilizou o desenvolvimento de sistemas automatizados para a detecção e classificação de doenças respiratórias a partir de imagens de raios-X (Khan et al., 2021).

Modelos híbridos baseados em “Machine Learning” [ML] e “Deep Learning” [DL] mostraram resultados promissores na análise de radiografias de tórax para a detecção de pneumonia (Mustapha et al, 2025; Abueed et al., 2025; Akinbo et al., 2024). As “Convolutional Neural Networks” [CNN], como “Visual Geometry Group Network” [VGGNet], “Residual Network” [ResNet], “Densely Connected Convolutional Networks” [DenseNet] e “Extreme Inception” [Xception], foram amplamente utilizadas como extratoras de características (Varshni et al., 2019), sendo frequentemente combinadas com classificadores supervisionados, como “Random Forest” [RF], “Extreme Gradient Boosting” [*XGBoost*] e “Support Vector Machine” [SVM], em tarefas de classificação (Sharma e Guleira, 2023). Além disso, a aprendizagem por transferência permitiu o aproveitamento de pesos pré-treinados em grandes bases de dados, o que otimizou o treinamento e melhorou a capacidade de generalização dos modelos em conjuntos de dados médicos limitados (El Zein et al., 2021; Jain et al., 2020; Güler e Polat, 2022).

Neste contexto, o trabalho propõe o desenvolvimento e a avaliação de um modelo híbrido de classificação para detecção de pneumonia em radiografias de tórax, utilizando as redes VGGNet e ResNet para extrair características, combinadas aos algoritmos RF, XGBoost e SVM na etapa de classificação para auxiliar no diagnóstico.

Metodologia

A pesquisa adotou um estudo de caso, pois aplicou diferentes modelos de aprendizado a um mesmo conjunto de dados. A proposta metodológica deste trabalho incluiu quatro etapas principais: preparação dos dados, extração de características, classificação e avaliação dos modelos, ilustrada na Figura 1 e descritas a seguir:

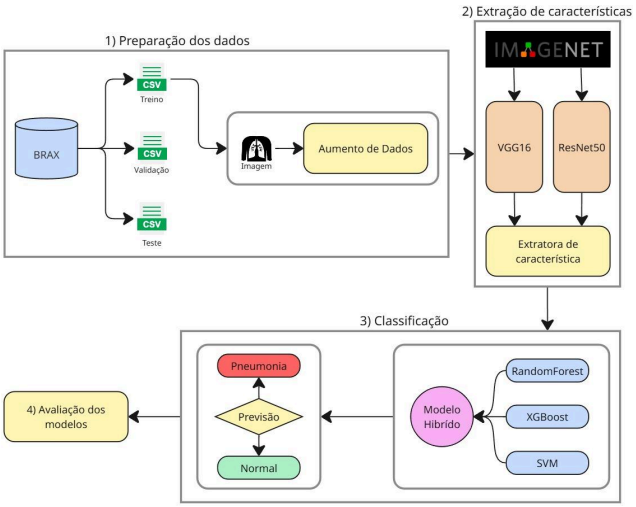

Figura 1. Diagrama da metodologia
Fonte: Dados originais da pesquisa

- Preparação dos dados: os dados do conjunto “Brazilian Labeled Chest X-ray Dataset” [BRAX] foram filtrados, rotulados de forma binária (pneumonia e normal), balanceados e divididos em conjuntos de treino, validação e teste. Em seguida, as imagens do conjunto de treino passaram por aumento de dados.
- Extração de características: as imagens foram inseridas em CNNs pré-treinadas, submetidas à técnica de ajuste fino parcial. Após a remoção da última camada de classificação, essas redes passaram a atuar como extratoras de características.
- Classificação: a partir das características extraídas, os dados foram utilizados no treinamento dos classificadores e na realização das predições.
- Avaliação dos modelos: por fim, foram avaliadas as métricas de desempenho dos modelos no conjunto de teste, o que permitiu a comparação entre as diferentes combinações de extratores e classificadores.

Base de dados

O estudo utilizou o conjunto BRAX, um banco de dados composto por 40.967 imagens radiográficas provenientes de 24.959 estudos de 19.351 pacientes, obtidos no Hospital Israelita Albert Einstein, em São Paulo, Brasil. (Reis et al., 2022).

Os rótulos das imagens derivam de relatórios radiológicos em texto livre, escritos em português brasileiro e processados por técnicas de Processamento de Linguagem Natural [PLN]. O método de rotulagem utilizou uma adaptação do “CheXpert”, com detecção de negação e incerteza em língua portuguesa, o que garantiu consistência semântica e precisão clínica. O BRAX foi desenvolvido com foco na representatividade da população brasileira e na privacidade dos pacientes, garantindo anonimização e critérios éticos de inclusão.

A escolha do BRAX ocorreu por seu grande volume de dados e por sua documentação detalhada, características que o tornam adequado para o desenvolvimento e a validação de modelos baseados em ML e DL voltados à detecção de pneumonia.

Preparação dos dados

Na etapa de preparação dos dados, o conjunto foi balanceado e dividido em treino, validação e teste. Em seguida, foi aplicada a técnica de aumento de dados, utilizada para lidar com o desequilíbrio entre as classes, especialmente quando houve menos amostras da classe pneumonia em relação à classe normal. Essa abordagem gerou imagens sintéticas e aumentou o número de amostras disponíveis para treinamento. Além disso, contribuiu para

reduzir o sobreajuste e melhorar a capacidade de generalização do modelo (Dardouri, 2025).

Extração de características

Para a etapa de extração de características, o estudo utilizou duas redes neurais convolucionais pré-treinadas no “ImageNet”, a ResNet50 e a VGG16, por meio da aprendizagem por transferência (Manickam et al., 2021). Ambas as arquiteturas passaram por ajuste fino parcial e foram utilizadas sem as camadas originais de classificação, funcionando apenas como extratoras de características (Varsho et al., 2019).

A ResNet50 consistiu em uma arquitetura profunda composta por 50 camadas convolucionais, que utilizou blocos residuais com conexões de atalho. Essa estrutura permitiu o fluxo direto da informação entre as camadas, evitou o problema do desaparecimento do gradiente e preservou informações relevantes durante o treinamento, o que resultou em extrações de alta qualidade (Sunil KUMAR e Harish KUMAR, 2023).

Já a VGG16 foi composta por 13 camadas convolucionais e 5 camadas de “max pooling”, seguidas de 3 camadas totalmente conectadas. Essa rede foi reconhecida por sua arquitetura simples e profunda, que proporcionou extração robusta de vetores de características, sendo amplamente utilizada em tarefas médicas de classificação radiográfica (Avola et al., 2022).

Classificação

A etapa de classificação utilizou as características extraídas pelas CNNs como entrada para três algoritmos supervisionados:

- RF: método de conjunto baseado em múltiplas árvores de decisão, que combina suas previsões para reduzir a variância e aumentar a robustez do modelo. É especialmente eficaz em dados médicos com atributos ruidosos ou correlacionados (Brindha et al., 2024).
- XGBoost: algoritmo de “boosting” baseado em árvores de decisão, que realiza a otimização da função de perda de forma aditiva, controlando a complexidade do modelo. Destaca-se pela alta precisão preditiva e eficiência computacional em conjuntos de dados extensos e heterogêneos (Rajeashwari e Arunesh, 2024).
- SVM: algoritmo que busca um hiperplano ótimo para separar classes distintas em um espaço de alta dimensão, minimizando os erros de classificação estrutural. É

amplamente aplicado em tarefas binárias, como a distinção entre radiografias normais e com pneumonia (Sourab e Kabir, 2022).

Avaliação

Nesta etapa, o estudo avaliou as combinações dos modelos com base em métricas amplamente utilizadas na literatura de aprendizado de máquina aplicada à área médica, obtidas a partir da matriz de confusão: acurácia, precisão, revocação ou sensibilidade e pontuação F1 (Al Mamlook et al., 2020; Géron, 2021; Grus, 2020). Por fim, a curva “Receiver Operating Characteristic” [ROC] demonstrou a capacidade diagnóstica do sistema classificador binário, enquanto a “Area Under the ROC Curve” [AUC-ROC] forneceu um único valor escalar que resumiu o desempenho geral do modelo em todos os limites possíveis de classificação.

Resultados e Discussão

Os resultados foram apresentados a partir das etapas metodológicas descritas anteriormente. Cada fase do processo: preparação dos dados, extração de características, classificação e avaliação dos modelos. Os tópicos a seguir estão organizados de forma espelhada à metodologia adotada, permitindo uma compreensão clara e sequencial da evolução do projeto.

Preparação dos dados

Na etapa de preparação dos dados, o estudo utilizou um arquivo CSV contendo os dados rotulados de cada paciente, inclusive o caminho para suas respectivas imagens. O conjunto original apresentou várias classes, como normal, pneumonia e outras doenças. Esse arquivo foi convertido para um formato binário, contendo apenas as classes normal e pneumonia. Em seguida, o conjunto foi balanceado e dividido em treino, validação e teste, ilustrado na Figura 2.

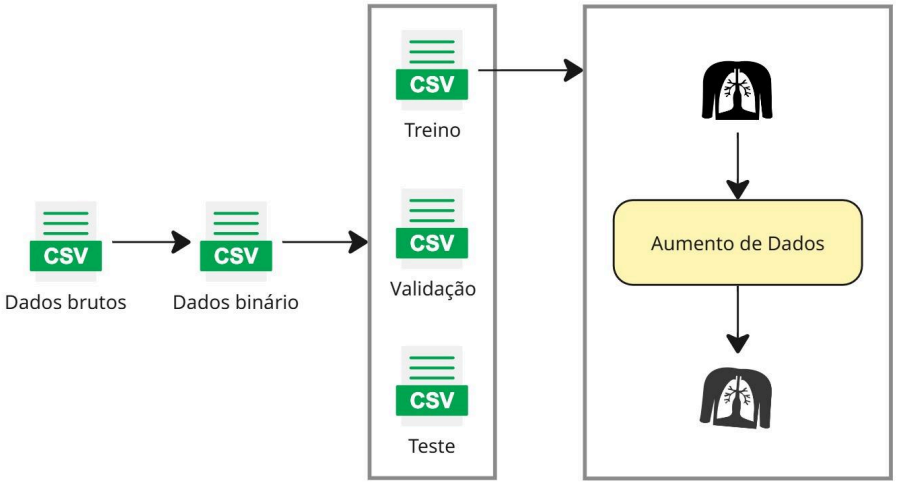

Figura 2. Diagrama preparação dos dados
Fonte: Resultados originais da pesquisa

Os dados foram divididos em conjuntos de treinamento (70%), validação (20%) e teste (10%), respeitando a separação por paciente, de modo a evitar que imagens de um mesmo paciente aparecem em conjuntos diferentes e causando sobreajuste. Devido ao forte desbalanceamento entre as classes, com 29.009 imagens da classe normal e 774 imagens da classe pneumonia, o estudo realizou três experimentos com estratégias de amostragem para reduzir esse problema.

No primeiro experimento, o estudo utilizou subamostragem manual em todos os conjuntos, com redução da classe majoritária para torná-la mais proporcional à classe minoritária, conforme a Tabela 1. No segundo experimento, o estudo empregou subamostragem aleatória com “RandomUnderSampler” [RUS] apenas no conjunto de treinamento, removendo aleatoriamente amostras da classe majoritária e preservando a distribuição original nos conjuntos de validação e teste, conforme a Tabela 2. No terceiro experimento, o estudo aplicou a técnica de sobreamostragem “Synthetic Minority Oversampling Technique” [SMOTE], que gerou artificialmente novas amostras da classe minoritária por meio da interpolação entre exemplos existentes e seus vizinhos mais próximos.

Tabela 1. Distribuição das imagens - Subamostragem manual

Conjunto	Normal	Pneumonia
Treinamento	712	538
Validação	213	156
Teste	81	80

Fonte: Resultados originais da pesquisa

Tabela 2. Distribuição das imagens - RUS

Conjunto	Normal	Pneumonia
Treinamento	729	538
Validação	5799	161
Teste	2814	75

Fonte: Resultados originais da pesquisa

Tabela 3. Distribuição das imagens - SMOTE

Conjunto	Normal	Pneumonia
Treinamento	20396	538
Validação	5799	161
Teste	2814	75

Fonte: Resultados originais da pesquisa

Após comparar as estratégias de balanceamento avaliadas, o estudo escolheu a subamostragem manual para as etapas seguintes, com uso da métrica “balanced accuracy score” para problemas de classificação binária em conjuntos desbalanceados. Essa abordagem apresentou a melhor média, de 70,0%, superando o SMOTE, com 67,2%, e o RUS, com 65,5%, apresentado na Tabela 4.

Tabela 4. Médias das técnicas de balanceamento

Modelos híbridos	Técnicas de balanceamento		
	Manual (%)	RUS (%)	SMOTE (%)
VGG16 + RF	68,4	64,7	70,2
VGG16 + XGB	70,4	61,5	64,1
VGG16 + SVM	69,1	66,9	62,7
ResNet50 + RF	69,6	66,2	68,8
ResNet50 + XGB	71,0	59,7	68,7
ResNet50 + SVM	72,3	69,5	65,6
Média	70,0	65,5	67,2

Fonte: Resultados originais da pesquisa

Os parâmetros de pré-processamento aplicados ao conjunto de treinamento incluíram aumento de dados e normalização das imagens, conforme a Tabela 5. As imagens passaram por redimensionamento, ajuste de brilho e contraste, inversão horizontal aleatória com determinada probabilidade e normalização com os parâmetros padrão do “ImageNet”.

Tabela 5. Parâmetros de aumento de dados e normalização

Transformação	Parâmetro	Valor
RandomResizedCrop	Tamanho de saída	224 × 224
RandomResizedCrop	Escala	0.85 a 1
ColorJitter	Brilho	0.10
ColorJitter	Contraste	0.20
RandomHorizontalFlip	Probabilidade	0.3
Normalize	Média	[0.485, 0.456, 0.406]
Normalize	Desvio padrão	[0.229, 0.224, 0.225]

Fonte: Resultados originais da pesquisa

Extração de Características

A aprendizagem por transferência foi aplicada a modelos pré-treinados no "ImageNet". Esses modelos serviram como base e passaram por ajuste fino parcial para a detecção de pneumonia, conforme ilustrado na Figura 3.

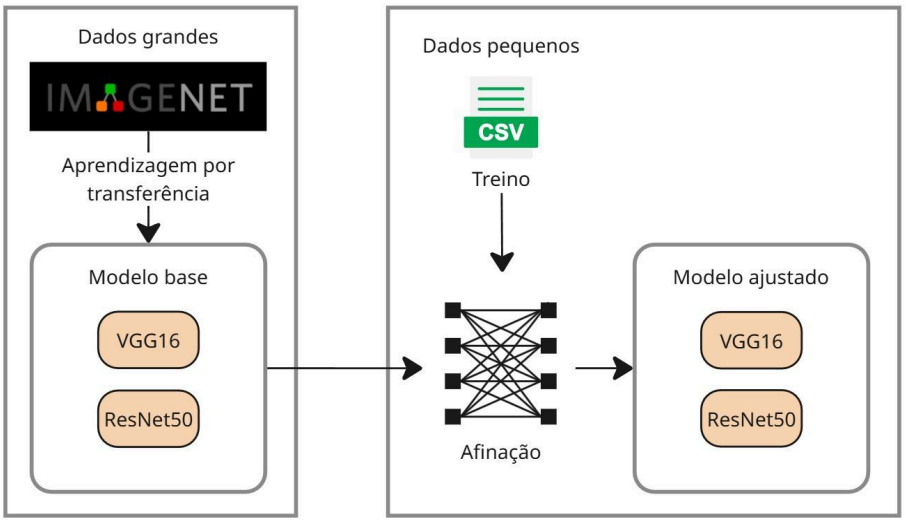

Figura 3. Diagrama aprendizagem por transferência e ajuste fine parcial
Fonte: Resultados originais da pesquisa

Nesse ajuste, a maior parte da "backbone" da CNN permaneceu congelada, enquanto apenas as camadas finais foram descongeladas e treinadas. A camada classificadora original foi removida e substituída por uma nova "head" linear para classificação binária. Dessa forma, a rede preservou conhecimentos gerais e adaptou sua parte final ao problema específico.

Durante o treinamento, a nova "head" gerou a saída utilizada no cálculo da função de perda. O processo de "backpropagation" atualizou a "head" e as camadas finais descongeladas, o que tornou as características extraídas mais adequadas à detecção de

pneumonia. Esse ajuste foi monitorado pelas métricas de erro de treinamento (“train loss”) e erro de validação (“val loss”), o que permitiu identificar o ponto ideal de convergência e evitar sobreajuste, apresentadas na Tabela 5 e 6. Após essa etapa, a “head” foi descartada, permanecendo apenas sua contribuição no ajuste supervisionado da rede.

Tabela 5. Métricas de ajuste fino parcial - ResNet50

Épocas	Erro de treinamento	Erro de validação
1/8	0.6752	0.6539
2/8	0.6216	0.6320
3/8	0.5727	0.6152
4/8	0.5435	0.5979
5/8	0.5155	0.5871
6/8	0.5039	0.5949
7/8	0.4786	0.5959
8/8	0.4558	0.5837

Fonte: Resultados originais da pesquisa

Tabela 6. Métricas de ajuste fino parcial - VGG16

Épocas	Erro de treinamento	Erro de validação
1/8	0.6844	0.6581
2/8	0.6538	0.6432
3/8	0.6323	0.6277
4/8	0.5949	0.6277
5/8	0.5752	0.5999
6/8	0.5621	0.5911
7/8	0.5565	0.5837
8/8	0.5281	0.5793

Fonte: Resultados originais da pesquisa

Depois disso, as imagens passaram pelas CNNs VGG16 e ResNet50 ajustadas, que atuaram como extratoras de características. Para isso, a camada “Fully Connected” [FC] original de classificação, especificamente a FC 1000, foi removida de ambas as redes.

Com essa modificação, cada arquitetura passou a extrair apenas características relevantes das imagens, sem realizar a classificação final. A saída da VGG16 resultou em um vetor de 4096 características, enquanto a ResNet50 gerou um vetor de 2048 características, ilustrada na Figura 4.

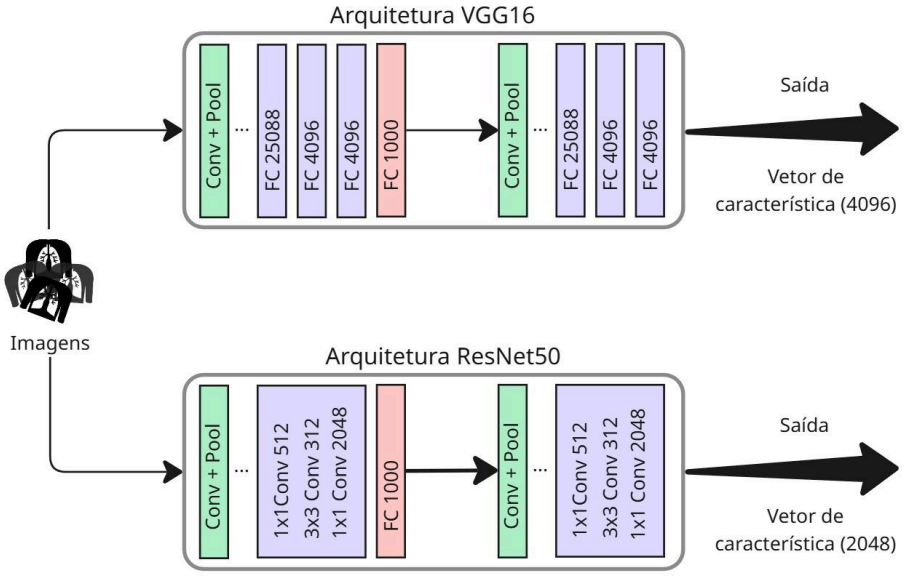

Figura 4. Diagrama de extração de características
Fonte: Resultados originais da pesquisa

Classificação

A partir dos vetores de características extraídos, o estudo aplicou os modelos de classificação RF, XGBoost e SVM, formando assim os modelos híbridos para prever se o paciente apresentava pneumonia ou condição normal, conforme ilustrado na Figura 4.

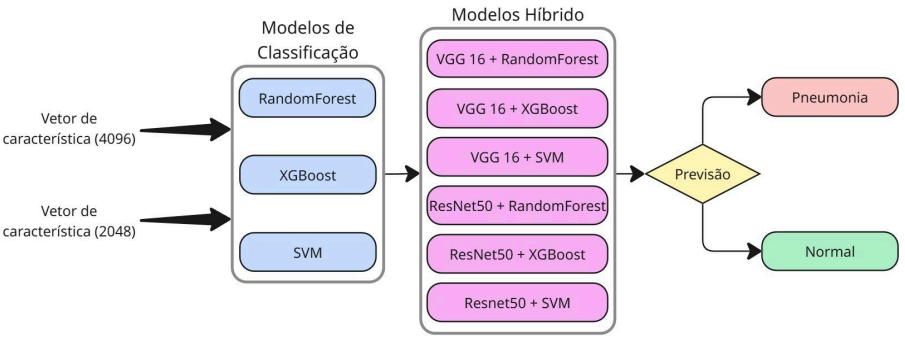

Figura 5. Diagrama de classificação
Fonte: Resultados originais da pesquisa

Para cada combinação entre extrator de características e modelo de classificação, o estudo realizou a busca dos melhores hiperparâmetros utilizando o “GridSearchCV”. A seleção utilizou como base a estratégia de “scoring” com valor de Pontuação F1 para alvos binários. Os melhores valores finais são apresentados na Tabela 7 e 8.

Tabela 7. Hiperparâmetros VGG16 com classificadores

VGG16 + RF	VGG16 + XGB	VGG16 + SVM
"class_weight": "balanced", "criterion": "entropy", "max_depth": null, "max_features": "sqrt", "min_samples_leaf": 4, "min_samples_split": 10, "n_estimators": 300	"n_estimators": 600 "learning_rate": 0.03 "max_depth": 4 "min_child_weight": 3 "gamma": 0.1 "subsample": 0.8 "colsample_bytree": 0.8	"clf__C": 1 "clf__class_weight": "balanced" "clf__gamma": "scale" "clf__kernel": "rbf"

Fonte: Resultados originais da pesquisa

Tabela 8. Hiperparâmetros ResNet50 com classificadores

ResNet50 + RF	ResNet50 + XGB	ResNet50 + SVM
"class_weight": "balanced_sampled" "criterion": "gini" "max_depth": 10 "max_features": "sqrt" "min_samples_leaf": 2 "min_samples_split": 10 "n_estimators": 800	"n_estimators": 1000 "learning_rate": 0.01 "max_depth": 5 "min_child_weight": 1 "gamma": 0.0 "subsample": 1.0 "colsample_bytree": 0.8	"clf__C": 1 "clf__class_weight": "balanced" "clf__gamma": "scale" "clf__kernel": "rbf"

Fonte: Resultados originais da pesquisa

Avaliação

A avaliação dos modelos utilizou as métricas descritas anteriormente na metodologia, com destaque para a revocação, por se tratar de uma tarefa de classificação médica. Essa escolha se justificou porque, em exames de raio-X de tórax, deixar de identificar um caso real de pneumonia representou um erro mais grave do que classificar incorretamente um paciente saudável como doente. Em outras palavras, um falso negativo poderia atrasar o diagnóstico e o início do tratamento, aumentando o risco clínico para o paciente.

De modo geral, os resultados mostraram que as duas extratoras de características, VGG16 e ResNet50, apresentaram desempenho consistente quando combinadas com os classificadores avaliados. No entanto, os melhores resultados em revocação foram obtidos com os classificadores RF e XGBoost, enquanto o SVM apresentou valores inferiores na identificação dos casos positivos, embora tenha alcançado melhor precisão.

Os resultados demonstrados na Tabela 9 mostraram que o modelo VGG16 + XGBoost obteve o melhor desempenho no conjunto de teste, com revocação de 0.950, além da maior acurácia, de 0.720, e da melhor pontuação F1, de 0.772. Resultados semelhantes foram observados com o modelo ResNet50 + XGBoost, que apresentou revocação de 0.900.

Tabela 9. Métricas de avaliação do resultado final

Modelo híbrido	Conjunto	Acurácia	Precisão	Revocação	Pontuação F1	AUC-ROC
VGG16 + RF	Validação	0.659	0.565	0.840	0.675	0.760
VGG16 + RF	Teste	0.683	0.628	0.887	0.736	0.782
VGG16 + XGB	Validação	0.669	0.569	0.897	0.697	0.755
VGG16 + XGB	Teste	0.720	0.650	0.950	0.772	0.771
VGG16 + SVM	Validação	0.683	0.591	0.814	0.685	0.758
VGG16 + SVM	Teste	0.708	0.663	0.838	0.740	0.771
ResNet50 + RF	Validação	0.672	0.570	0.917	0.703	0.776
ResNet50 + RF	Teste	0.677	0.623	0.887	0.732	0.769
ResNet50 + XGB	Validação	0.661	0.559	0.942	0.702	0.779
ResNet50 + XGB	Teste	0.658	0.605	0.900	0.724	0.761
ResNet50 + SVM	Validação	0.696	0.596	0.872	0.708	0.783
ResNet50 + SVM	Teste	0.702	0.660	0.825	0.733	0.754

Fonte: Resultados originais da pesquisa

A matriz de confusão mostrou que o modelo VGG16 + XGBoost identificou corretamente a maior parte dos casos de pneumonia, com 140 acertos, e apresentou poucos falsos negativos, com 16 casos, o que confirmou sua alta revocação. Em contrapartida, o modelo gerou 106 falsos positivos ao classificar exames normais como pneumonia. Esse comportamento indicou que o modelo foi mais sensível para detectar pneumonia do que para reconhecer casos normais.

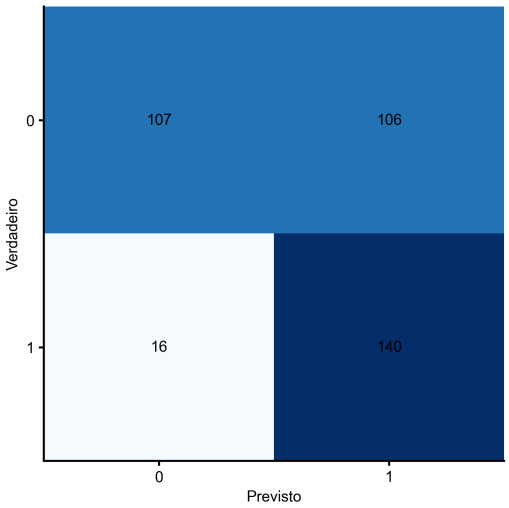

Figura 6. Matriz de confusão - VGG16 + XGBoost
Fonte: Resultados originais da pesquisa

Conforme ilustrado na Figura 7, o desempenho do modelo na curva ROC apresentou "Area Under the Curve" [AUC] de 0.77, o que demonstrou capacidade razoável de distinguir imagens com e sem pneumonia. Além disso, a curva Precisão-Revocação apresentou "Average Precision" [AP] de 0.75, mostrando que o modelo manteve bom equilíbrio entre precisão e revocação. No entanto, foi possível observar redução da precisão à medida que a revocação aumentou, o que indicou maior ocorrência de falsos positivos em cenários mais sensíveis.

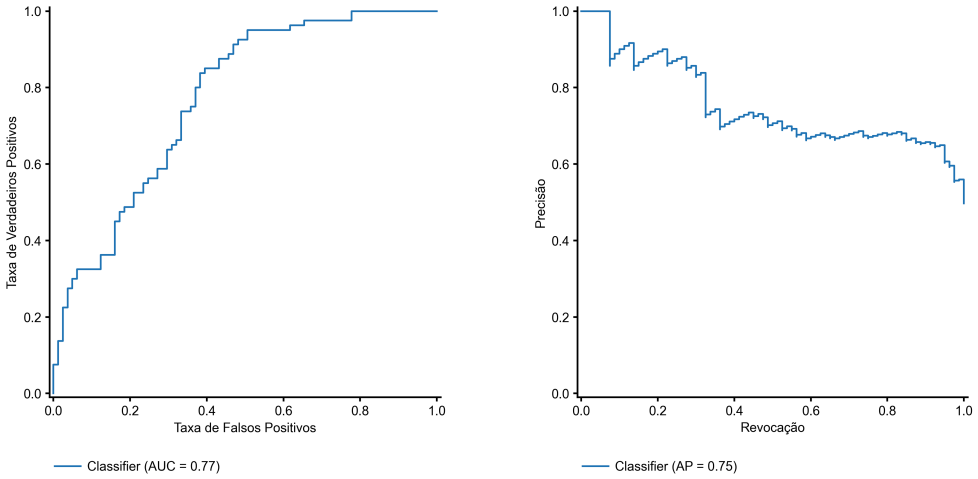

(A) (B)

Figura 7. Desempenho do modelo VGG16 + XGBoost no conjunto de teste
Nota: A = curva ROC VGG16; B = curva precisão-revocação

Considerações Finais

Este estudo atingiu o objetivo proposto de desenvolver e avaliar um modelo híbrido para a detecção de pneumonia em imagens de raio-X de tórax, combinando CNNs pré-treinadas com classificadores. A abordagem adotada mostrou que o uso de CNNs como extratoras de características, associado a algoritmos clássicos de classificação, foi adequado para classificar casos normais e com pneumonia.

De modo geral, os resultados indicaram desempenho consistente entre os modelos híbridos avaliados, com destaque para as combinações baseadas em XGBoost com VGG16 e ResNet50, que apresentaram melhor equilíbrio geral para a tarefa.

Também foi possível observar que a preparação dos dados teve papel importante no desempenho final, especialmente devido ao forte desbalanceamento entre as classes. Nesse contexto, a priorização da revocação foi importante para o problema estudado, já que, em aplicações médicas, reduzir falsos negativos foi muito relevante.

Como limitações do estudo, as restrições de hardware disponíveis para a execução dos experimentos, inviabilizou a adoção de abordagens computacionalmente mais custosas, como uma validação cruzada mais ampla em todo o processo. Além disso, a baixa quantidade de casos de pneumonia no conjunto original também representou uma limitação importante, pois restringiu a diversidade de exemplos positivos disponíveis para treinamento e avaliação dos modelos híbridos.

Referências

Abueed, M. A. M.; Nor, D. M.; Ibrahim, N.; Ogier, J.. Pneumonia Detection Using Transfer Learning: A Systematic Literature Review. International Journal of Advanced Computer Science and Applications (IJACSA), v.16, n.2, p.1032–1045, 2025.

Akinbo, R. S. et al. Classification of Pneumonia Disease Using Machine Learning Techniques: A Systematic Review. International Journal of Advances in Engineering and Management (IJAEM), v.6, n.8, p.1–11, 2024. DOI: 10.35629/5252-06080111

Avola, D.; Bacciu, A.; Cinque, L.; Fagioli, A.; Marina, M. R.; Taiello, R.. Study on Transfer Learning Capabilities for Pneumonia Classification in Chest X-Rays Images. Computer Methods and Programs in Biomedicine, v.221, 2022. DOI: 10.1016/j.cmpb.2022.106833.

Ayan, E.; Karabulut, B.; Ünver, H. M.. Diagnosis of Pediatric Pneumonia with Ensemble of Deep Convolutional Neural Networks in Chest X-Ray Images. Arabian Journal for Science and Engineering, v.47, p.2123–2139, 2022. DOI: 10.1007/s13369-021-06127-z.

Al Mamlook, R. E. et al. Investigation of the performance of machine learning classifiers for pneumonia detection in chest X-ray images. IEEE Xplore, 2020. DOI: 10.1109/EIT48999.2020.9208232.

Brindha, M. et al. Utilizing Random Forest to Diagnose Pneumonia in Children. In: IEEE International Conference on Artificial Intelligence for Internet of Things (AIIoT), 3., 2024. DOI: 10.1109/AIIoT58432.2024.10574685.

El Zein, O. M. et al. Transfer Learning Based Model for Pneumonia Detection in Chest X-Ray Images. International Journal of Intelligent Engineering and Systems, v.14, n.5, 2021. DOI: 10.22266/ijies2021.1031.06.

Géron, A.. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras e TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. 2. ed. Alta Books, 2020. ISBN 978-85-508-1548-3.

Grus, J.. Data Science do Zero: noções fundamentais com Python. 2. ed. Alta Books, 2020. ISBN 978-85-508-1176-8.

Güler, O.; Polat, K.. Classification Performance of Deep Transfer Learning Methods for Pneumonia Detection from Chest X-Ray Images. Journal of Artificial Intelligence and Systems, v.4, p.107–126, 2022. DOI: 10.33969/AIS.2022040107.

Jain, R.; Nagrath, P.; Kataria, G.; Kaushik, V. S.; Hemanth, D. J.. Pneumonia Detection in Chest X-Ray Images Using Convolutional Neural Networks and Transfer Learning. Measurement, v.165, 2020. DOI: 10.1016/j.measurement.2020.108046.

Khan, W.; Zaki, N.; Ali, L.. Intelligent Pneumonia Identification from Chest X-Rays: A Systematic Literature Review. IEEE Access, v.9, p.51747–51763, 2021. DOI: 10.1109/ACCESS.2021.3069937.

Kumar, S.; Kumar, H.. PneuML: A Novel Sequential Convolutional Neural Network-Based X-Ray Diagnostic System for Pneumonia in Contrast to Machine Learning and Pre-Trained Networks. U.P.B. Scientific Bulletin, Series C, v.85, n.4, 2023. ISSN 2286-3540.

Lim, W. S.. Pneumonia—Overview. In: Encyclopedia of Respiratory Medicine, 2nd ed. Elsevier, 2022. DOI: 10.1016/B978-0-12-801238-3.11636-8.

Ministério da Saúde. Pneumonia, 2025

Manickam, A.; Jiang, J.; Zhou, Y.; Sagar, A.v; Soundrapandiyan, R.; Samuel, R. D. J.. Automated Pneumonia Detection on Chest X-Ray Images: A Deep Learning Approach with Different Optimizers and Transfer Learning Architectures. Measurement, v.184, 2021. DOI: 10.1016/j.measurement.2021.109953.

Mustapha, B.; Zhou, Y.; Shan, C.; Xiao, Z.. Enhanced Pneumonia Detection in Chest X-Rays Using Hybrid Convolutional and Vision Transformer Networks. Current Medical Imaging, v.21, 2025. DOI: 10.2174/0115734056326685250101113959.

Dardouri, S.. Pneumonia Detection in X-Ray Chest Images Based on Convolutional Neural Networks and Data Augmentation Methods, 2025. DOI: 10.5220/0013147300003938

Organização Mundial da Saúde (OMS). *Pneumonia em Crianças*. Genebra: Organização Mundial da Saúde, 2021. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/pneumonia>

Rajeashwari, S.; Arunesh, K. Enhancing Pneumonia Diagnosis with Ensemble-Modified Classifier and Transfer Learning in Deep-CNN Based Classification of Chest Radiographs. Biomedical Signal Processing and Control, v.93, 2024. DOI: 10.1016/j.bspc.2024.106130.

Reis, E. P. et al. BRAX: Brazilian Labeled Chest X-Ray Dataset. Scientific Data, v.9, p.487, 2022. DOI: 10.1038/s41597-022-01608-8.

Sharma, S.; Guleira, K.. A Deep Learning-Based Model for the Detection of Pneumonia from Chest X-Ray Images Using VGG-16 and Neural Networks. Procedia Computer Science, v.218, p.357–366, 2023. DOI: 10.1016/j.procs.2023.01.018.

Sourab, S. Y.; Kabir, M. A.. A Comparison of Hybrid Deep Learning Models for Pneumonia Diagnosis from Chest Radiograms. Sensors International, v.3, 2022. DOI: 10.1016/j.sintl.2022.100167.

Varsho, D.; Nijhawan, R.; Thakral, K.; Mittal, A.; Agarwal, L.. Pneumonia Detection Using CNN-Based Feature Extraction. IEEE Xplore, 2019. DOI: 10.1109/ICECCT.2019.8869364.

Apêndice

Todos os scripts desenvolvidos ao longo do trabalho de conclusão de curso, incluindo etapas de preparação dos dados, extração de características, classificação e avaliação dos modelos, encontram-se organizados e comentados no seguinte repositório do GitHub:

- https://github.com/vitorAugusto2/pneumonia-brax

Este repositório é fundamental para o entendimento completo do processo metodológico empregado com os resultados dos demais modelos híbridos, bem como para a reprodutibilidade do estudo.